

Prevenção de ataques DDOS

Uso de aprendizado de máquina para a prevenção de ataques DDOS





Problema(DDOS)

Uma ataque DDoS tem como objetivo consumir os recursos de um servidor com requisições supérfluas ao ponto de indisponibilizar o seu serviço para usuários verdadeiros.



Ponto importante

Se o agente malicioso não conseguir consumir recursos suficientes do servidor, ele **NÃO** será capaz de alcançar o objetivo do ataque que seria negar o servidor para usuários reais.



Diversos tipos

Existem diversas formas de ataques DDoS, onde cada uma delas tem suas respectivas características. Exemplos:

- UDP flooding
- SYN flooding
- Vulnerabilidade no NetBios



Dataset CIC - DDoS2019

O dataset escolhido foi o CIC - DDoS de 2019, que possui dados gerados artificialmente.



Dados

- Dataset contém 88 features
- Nome das features mal formatado
- 6 não são numéricos:
 - Label
 - Flow ID
 - Simillar HTTP
 - Source IP
 - Destination IP
 - Timestamp
- Possui alguns registros vazios
- Dados contendo o resultado de operações matemáticas, como por exemplo desvio padrão, média, variância, etc.



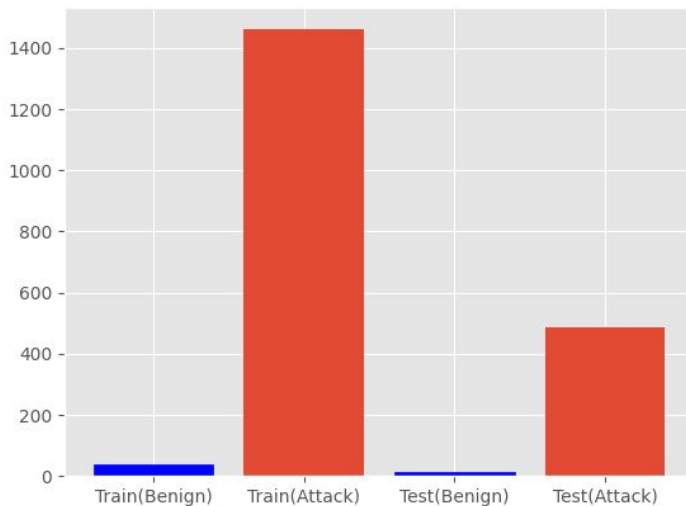
Excesso de dados

O arquivo com menos dados é o Portmap.csv e mesmo assim existe mais de 76.000 linhas de dados. Resampling se tornou necessário.



Distribuição

A distribuição é desbalanceada, com em torno de 90% de dados de ataque e apenas ~10% de dados benignos.





Objetivo da solução

A solução proposta deve cumprir com os seguintes objetivos:

- Deve bloquear requisições maliciosas o suficiente para impedir o uso excessivo dos recursos providos pelo servidor
- Conter o mínimo possível de casos falsos-positivos



Estimadores

Os estimadores utilizados foram:

- Random Forest
- KNN
- SVM




Hiperparâmetros

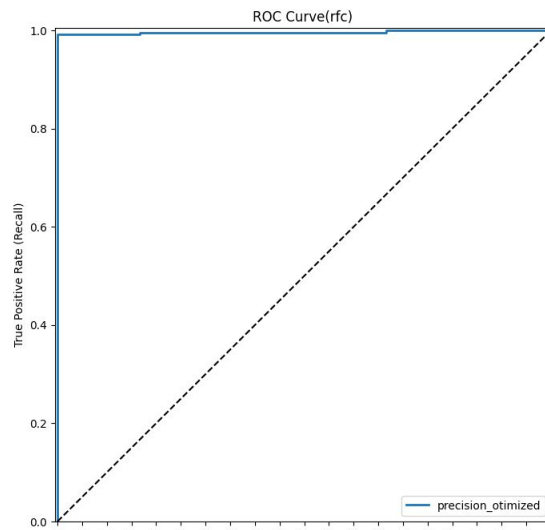
Para a otimização dos hiperparâmetros dos estimadores foi utilizado o Grid Search com o foco na métrica de **precisão**.



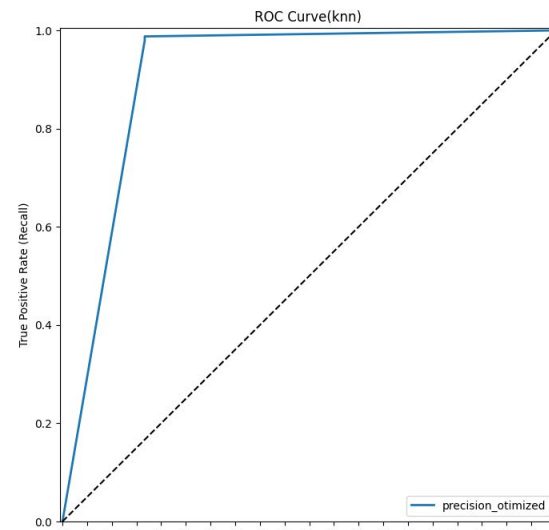
Resultados



0.983



0.996




0.909




Resultados


KNN



Random Forest



SVC





Preocupações

É comum a Random Forest gerar um *overfitting* e como ela teve um resultado tão excelente, gerou suspeitas.




Mitigar o problema do Falso-Positivo

Foi utilizado um limiar sobre a probabilidade de um dado pertencer a uma classe para garantir que ele seja considerado um ataque somente se o modelo tem um certo grau de certeza.




Resultados


KNN



Random Forest



SVC





Outras possíveis soluções

Por causa do fato de que os casos de falso-positivo foram tão baixo, outras soluções não foram implementadas.



Referências

<https://www.unb.ca/cic/datasets/ddos-2019.html>

https://scikit-learn.org/stable/user_guide.html

<https://pandas.pydata.org/docs/>